Detecção de fraudes de cartão de crédito

https://www.kaggle.com/mlg-ulb/creditcardfraud/

Objetivo

Dada uma compra efetuada com um cartão de crédito, identificar se essa transação é fraudulenta.

Dados

Cerca de 280 mil transações realizadas por clientes Europeus em setembro de 2013, das quais 99,98% são genuínas e 0,02%, fraudes.

Descobertas

Dados extremamente desbalanceados.

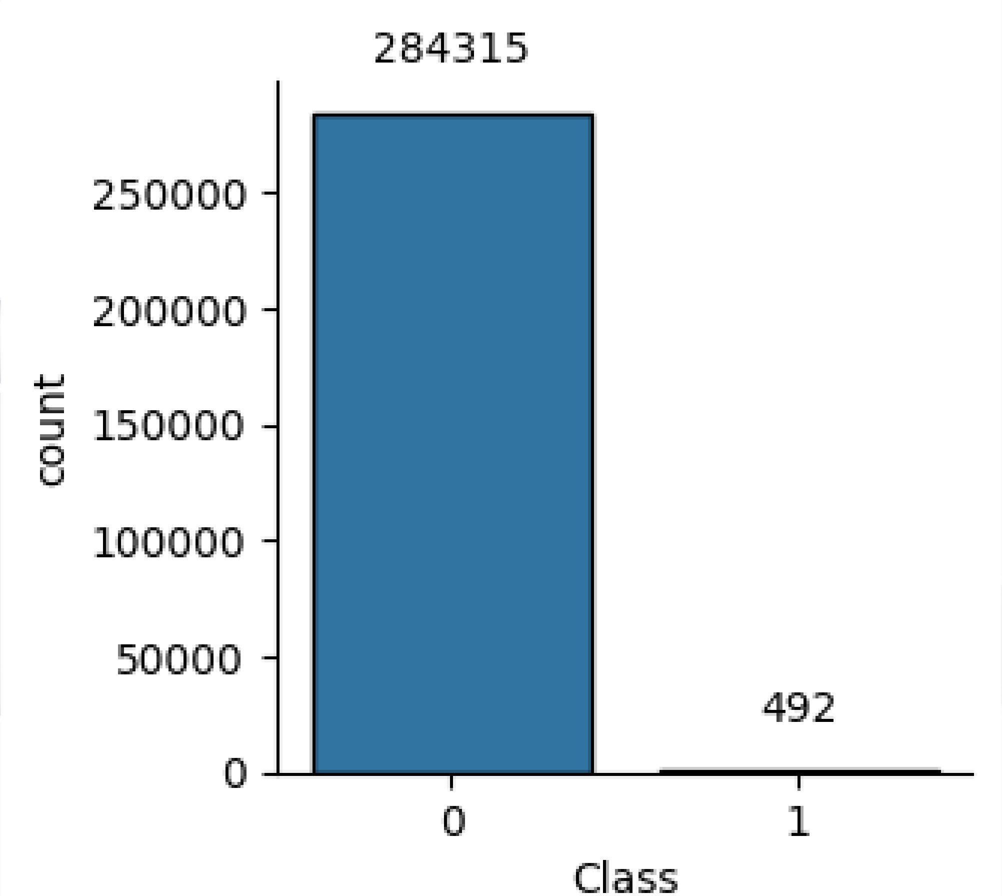

Descobertas (cont.)

Distribuições por classe

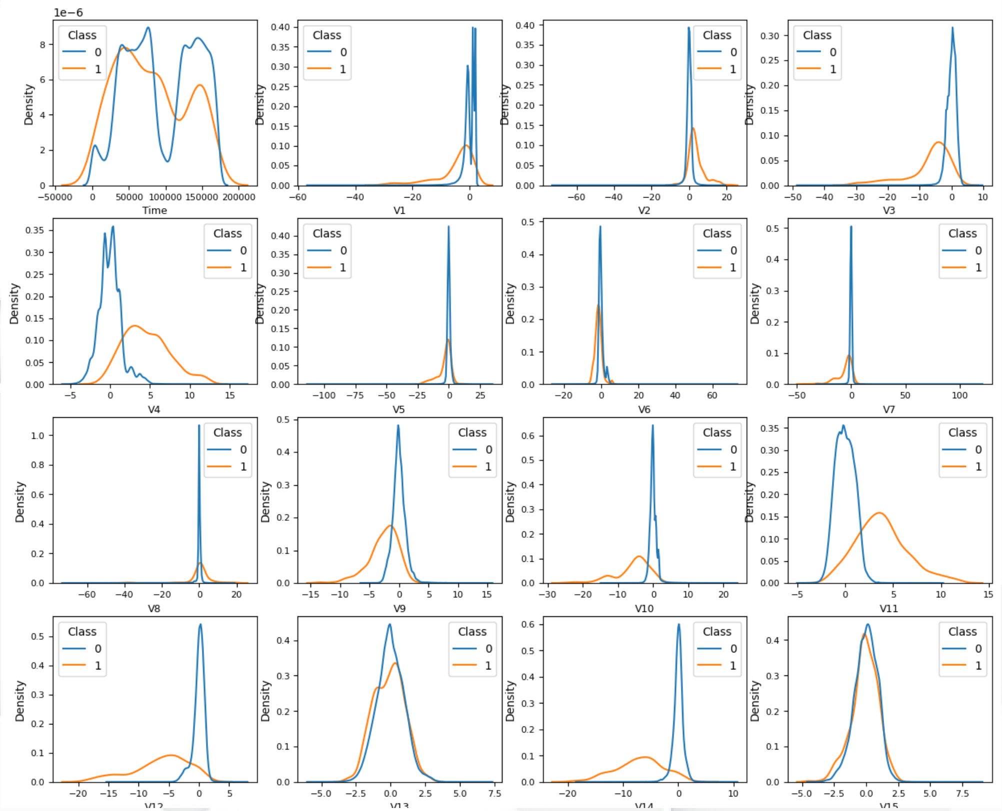

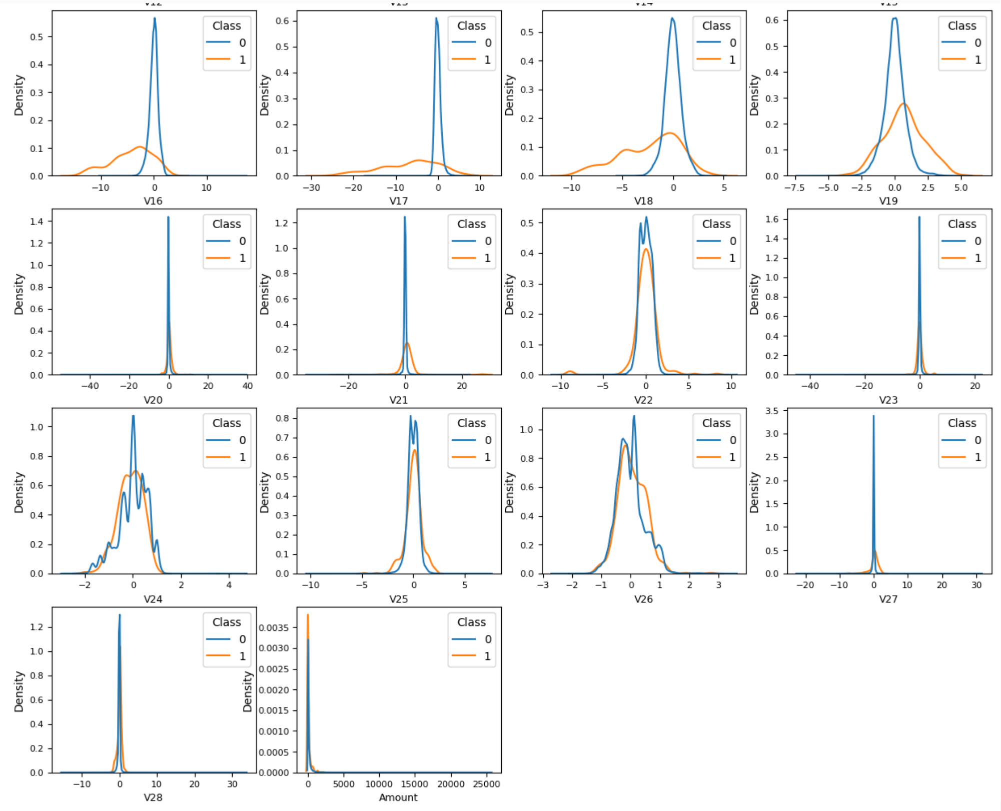

Descobertas (cont.)

Distribuições por classe

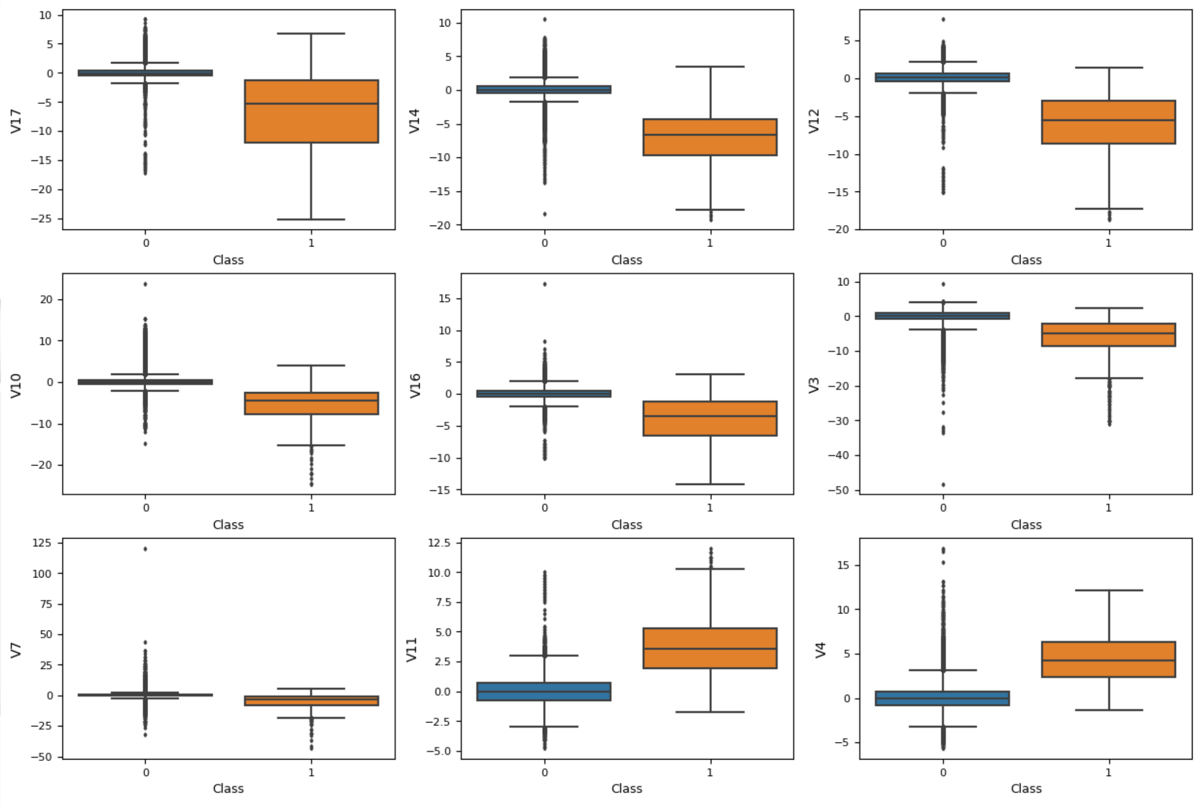

Descobertas (cont.)

Correlações indicam que as variáveis V_i realmente são componentes principais.

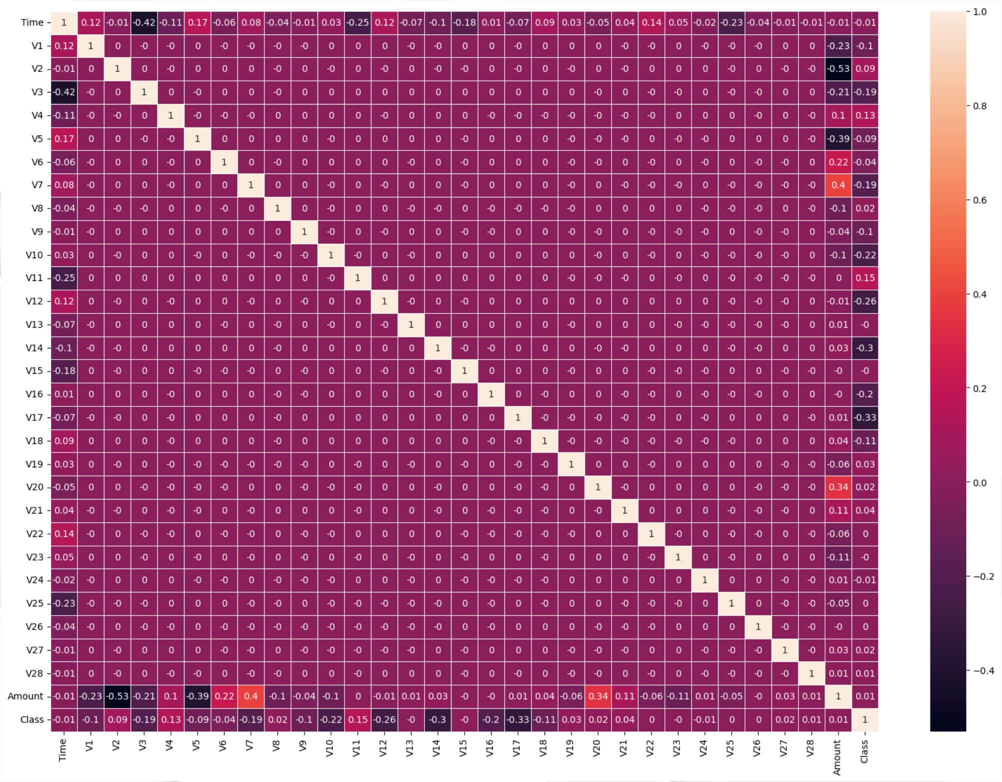

	Time	V1	V2	V3	V4	V5	V6	V7	V8	V9	V10	V11	V12	V13	V14	V15	V16	V17	V18	V19	V20	V21	V22	V23	V24	V25	V26	V27	V28	Amount	Class
Time	1	0.12	-0.01	-0.42	-0.11	0.17	-0.06	0.08	-0.04	-0.01	0.03	-0.25	0.12	-0.07	-0.1	-0.18	0.01	-0.07	0.09	0.03	-0.05	0.04	0.14	0.05	-0.02	-0.23	-0.04	-0.01	-0.01	-0.01	-0.01
V1	0.12	1	0	-0	-0	0	-0	-0	-0	-0	0	0	0	-0	-0	0	0	-0	0	0	0	-0	-0	0	-0	-0	-0	0	0	-0.23	-0.1
V2	-0.01	0	1	0	-0	0	0	0	-0	0	-0	0	-0	0	-0	-0	0	-0	0	-0	0	-0	0	0	0	-0	0	-0	-0	-0.53	0.09
V3	-0.42	-0	0	1	0	-0	0	0	-0	0	0	0	0	0	0	0	0	0	0	0	-0	0	-0	-0	0	-0	-0	0	0	-0.21	-0.19
V4	-0.11	-0	-0	0	1	-0	-0	-0	0	0	0	0	-0	0	0	0	-0	-0	-0	-0	-0	-0	-0	0	0	0	-0	0	-0	0.1	0.13
V5	0.17	0	0	-0	-0	1	0	0	0	0	-0	0	0	0	0	-0	0	0	0	-0	-0	-0	0	-0	-0	0	0	0	-0	-0.39	-0.09
V6	-0.06	-0	0	0	-0	0	1	0	-0	0	0	0	0	-0	0	-0	0	0	0	-0	-0	0	-0	0	-0	0	-0	-0	0	0.22	-0.04
V7	0.08	-0	0	0	-0	0	0	1	0	0	-0	0	-0	0	0	-0	0	0	0	-0	0	-0	-0	-0	0	-0	-0	-0	-0	0.4	-0.19
V8	-0.04	-0	-0	-0	0	0	-0	0	1	0	-0	0	0	-0	-0	0	-0	-0	-0	-0	0	0	0	0	-0	-0	-0	0	-0	-0.1	0.02
V9	-0.01	-0	0	0	0	0	0	0	0	1	-0	0	-0	0	0	-0	-0	0	0	-0	-0	0	-0	-0	-0	0	-0	-0	0	-0.04	-0.1
V10	0.03	0	-0	0	0	-0	0	-0	-0	-0	1	-0	0	-0	0	0	0	0	0	0	-0	0	-0	0	-0	-0	-0	-0	0	-0.1	-0.22
V11	-0.25	0	0	0	0	0	0	0	0	0	-0	1	0	0	0	0	0	0	0	-0	-0	-0	0	-0	0	-0	-0	-0	-0	0	0.15
V12	0.12	0	-0	0	-0	0	0	-0	0	-0	0	0	1	-0	0	-0	0	0	0	0	0	0	0	0	0	-0	-0	-0	0	-0.01	-0.26
V13	-0.07	-0	0	0	0	0	-0	0	-0	0	-0	0	-0	1	0	0	0	0	0	-0	0	0	0	-0	-0	-0	-0	-0	0	0.01	-0
V14	-0.1	-0	-0	0	0	0	0	0	-0	0	0	0	0	0	1	-0	-0	0	0	0	-0	-0	0	0	0	-0	-0	0	0	0.03	-0.3
V15	-0.18	0	-0	0	0	-0	-0	-0	0	-0	0	0	-0	0	-0	1	0	0	0	-0	0	0	-0	-0	-0	0	0	-0	-0	-0	-0
V16	0.01	0	0	0	-0	0	0	0	-0	-0	0	0	0	0	-0	0	1	0	-0	0	0	-0	-0	0	-0	-0	-0	0	0	-0	-0.2
V17	-0.07	-0	-0	0	-0	0	0	0	-0	0	0	0	0	0	0	0	0	1	-0	-0	-0	-0	-0	0	-0	0	0	0	-0	0.01	-0.33
V18	0.09	0	0	0	-0	0	0	0	-0	0	0	0	0	0	0	0	-0	-0	1	-0	-0	-0	-0	-0	-0	-0	0	0	0	0.04	-0.11
V19	0.03	0	-0	0	-0	-0	-0	-0	-0	-0	0	-0	0	-0	0	-0	0	-0	-0	1	0	0	-0	0	0	0	0	-0	-0	-0.06	0.03
V20	-0.05	0	0	-0	-0	-0	-0	0	0	-0	-0	-0	0	0	-0	0	0	-0	-0	0	1	-0	0	0	0	0	-0	-0	-0	0.34	0.02
V21	0.04	-0	-0	0	-0	-0	0	-0	0	0	0	-0	0	0	-0	0	-0	-0	-0	0	-0	1	0	0	0	-0	-0	-0	0	0.11	0.04
V22	0.14	-0	0	-0	-0	0	-0	-0	0	-0	-0	0	0	0	0	-0	-0	-0	-0	-0	0	0	1	-0	0	-0	-0	0	-0	-0.06	0
V23	0.05	0	0	-0	0	-0	0	-0	0	-0	0	-0	0	-0	0	-0	0	0	-0	0	0	0	-0	1	0	-0	0	0	0	-0.11	-0
V24	-0.02	-0	0	0	0	-0	-0	0	-0	-0	-0	0	0	-0	0	-0	-0	-0	-0	0	0	0	0	0	1	0	0	-0	-0	0.01	-0.01
V25	-0.23	-0	-0	-0	0	0	0	-0	-0	0	-0	-0	-0	-0	-0	0	-0	0	-0	0	0	-0	-0	-0	0	1	0	-0	-0	-0.05	0
V26	-0.04	-0	0	-0	-0	0	-0	-0	-0	-0	-0	-0	-0	-0	-0	0	-0	0	0	0	-0	-0	-0	0	0	0	1	-0	-0	-0	0
V27	-0.01	0	-0	0	0	0	-0	-0	0	-0	-0	-0	-0	-0	0	-0	0	0	0	-0	-0	-0	0	0	-0	-0	-0	1	-0	0.03	0.02
V28	-0.01	0	-0	0	-0	-0	0	-0	-0	0	0	-0	0	0	0	-0	0	-0	0	-0	-0	0	-0	0	-0	-0	-0	-0	1	0.01	0.01
Amount	-0.01	-0.23	-0.53	-0.21	0.1	-0.39	0.22	0.4	-0.1	-0.04	-0.1	0	-0.01	0.01	0.03	-0	-0	0.01	0.04	-0.06	0.34	0.11	-0.06	-0.11	0.01	-0.05	-0	0.03	0.01	1	0.01
Class	-0.01	-0.1	0.09	-0.19	0.13	-0.09	-0.04	-0.19	0.02	-0.1	-0.22	0.15	-0.26	-0	-0.3	-0	-0.2	-0.33	-0.11	0.03	0.02	0.04	0	-0	-0.01	0	0	0.02	0.01	0.01	1

Descobertas (cont.)

Correlações com o alvo

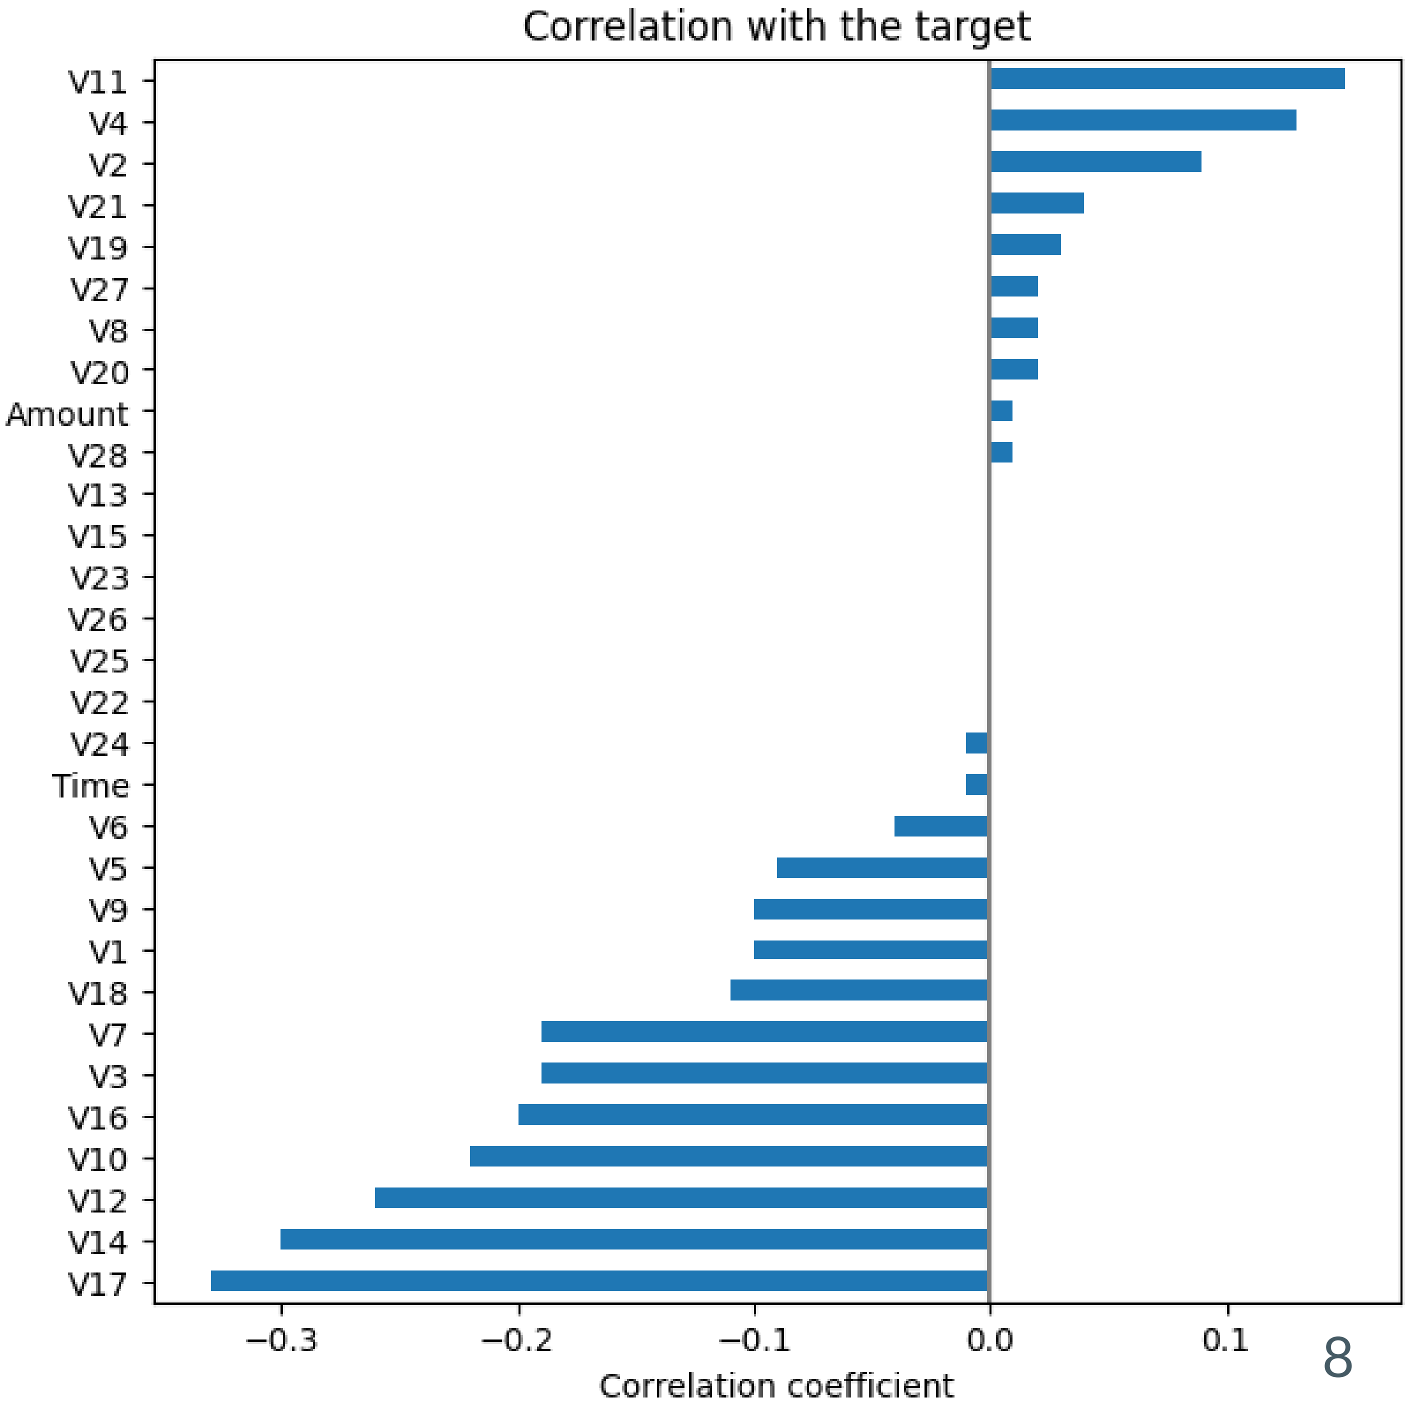

Modelos

1. regressão logística e 2) *gradient boosting*.

Métrica

Área sob a curva de precisão-revocação (AUC-PR).

Resultados

A regressão logística atingiu uma AUC-PR de 0.72, enquanto o *gradient boosting* atingiu 0.85.

Resultados (cont.)

Coeficientes da regressão logística

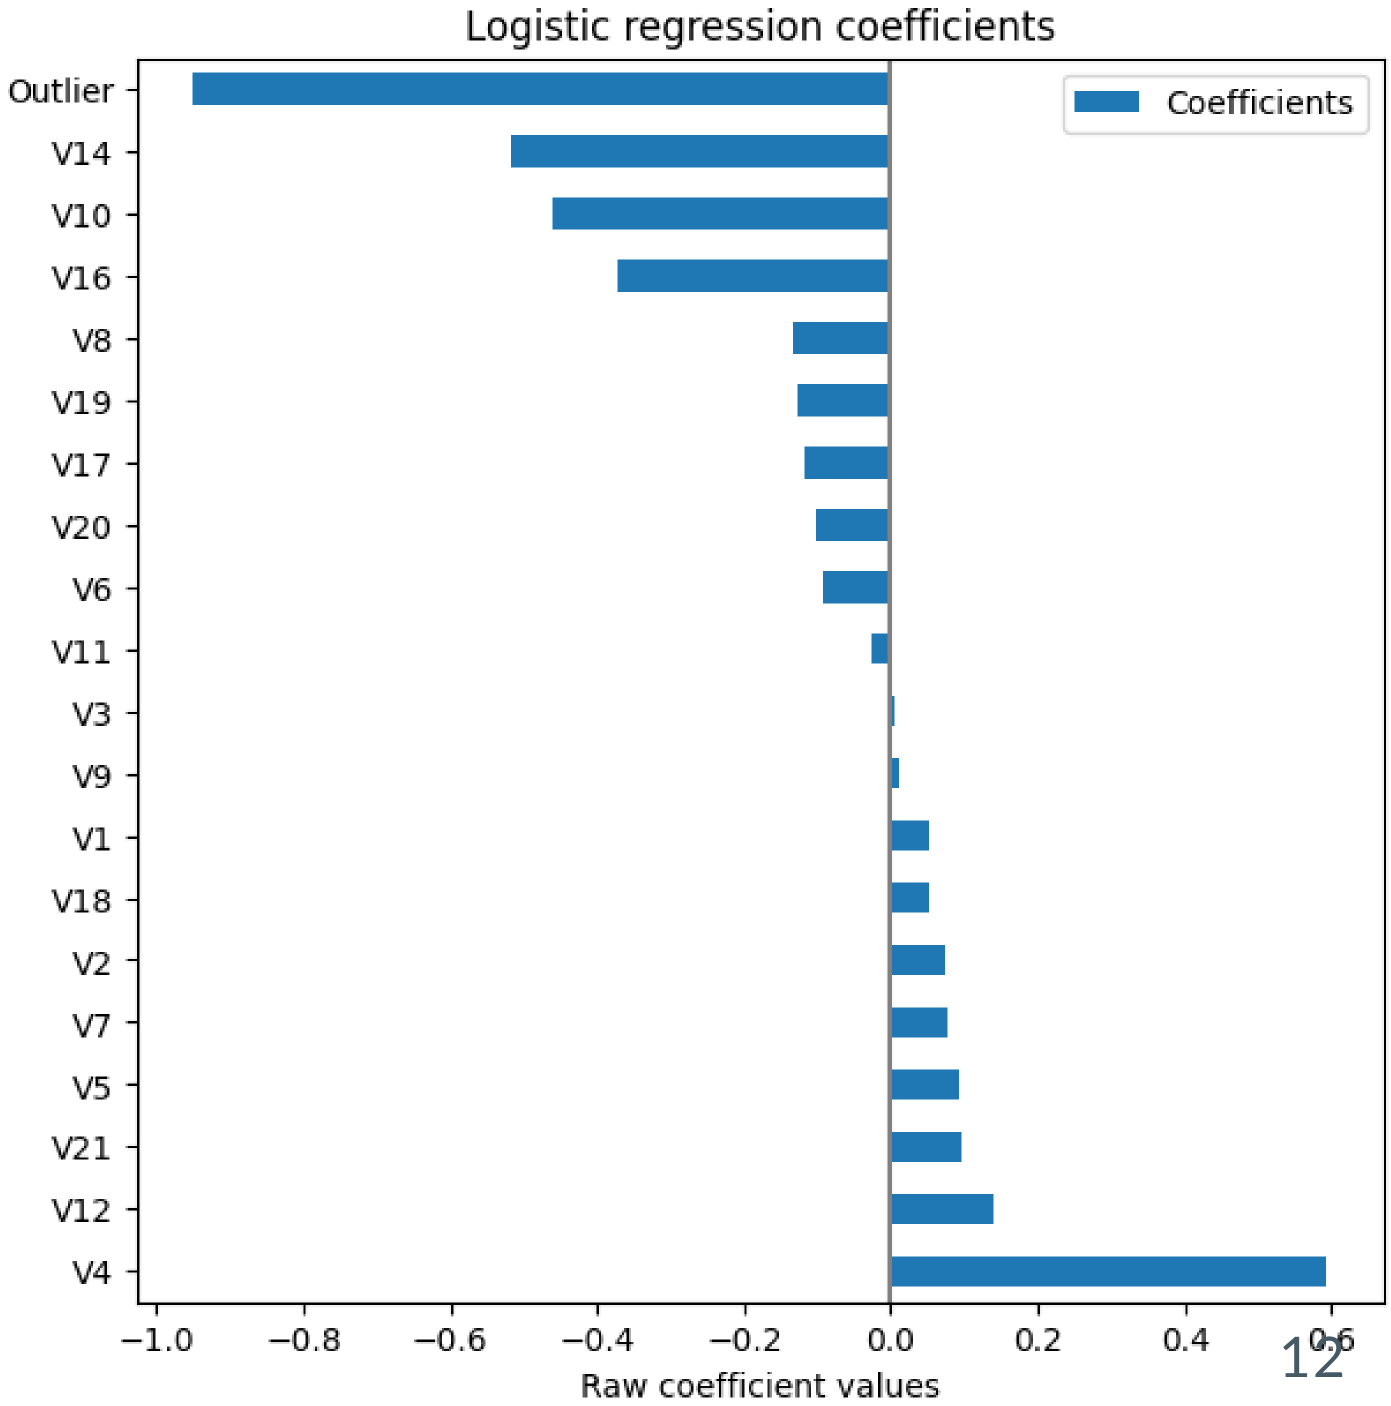

Resultados (cont.)

Curva de precisão-revocação da regressão logística

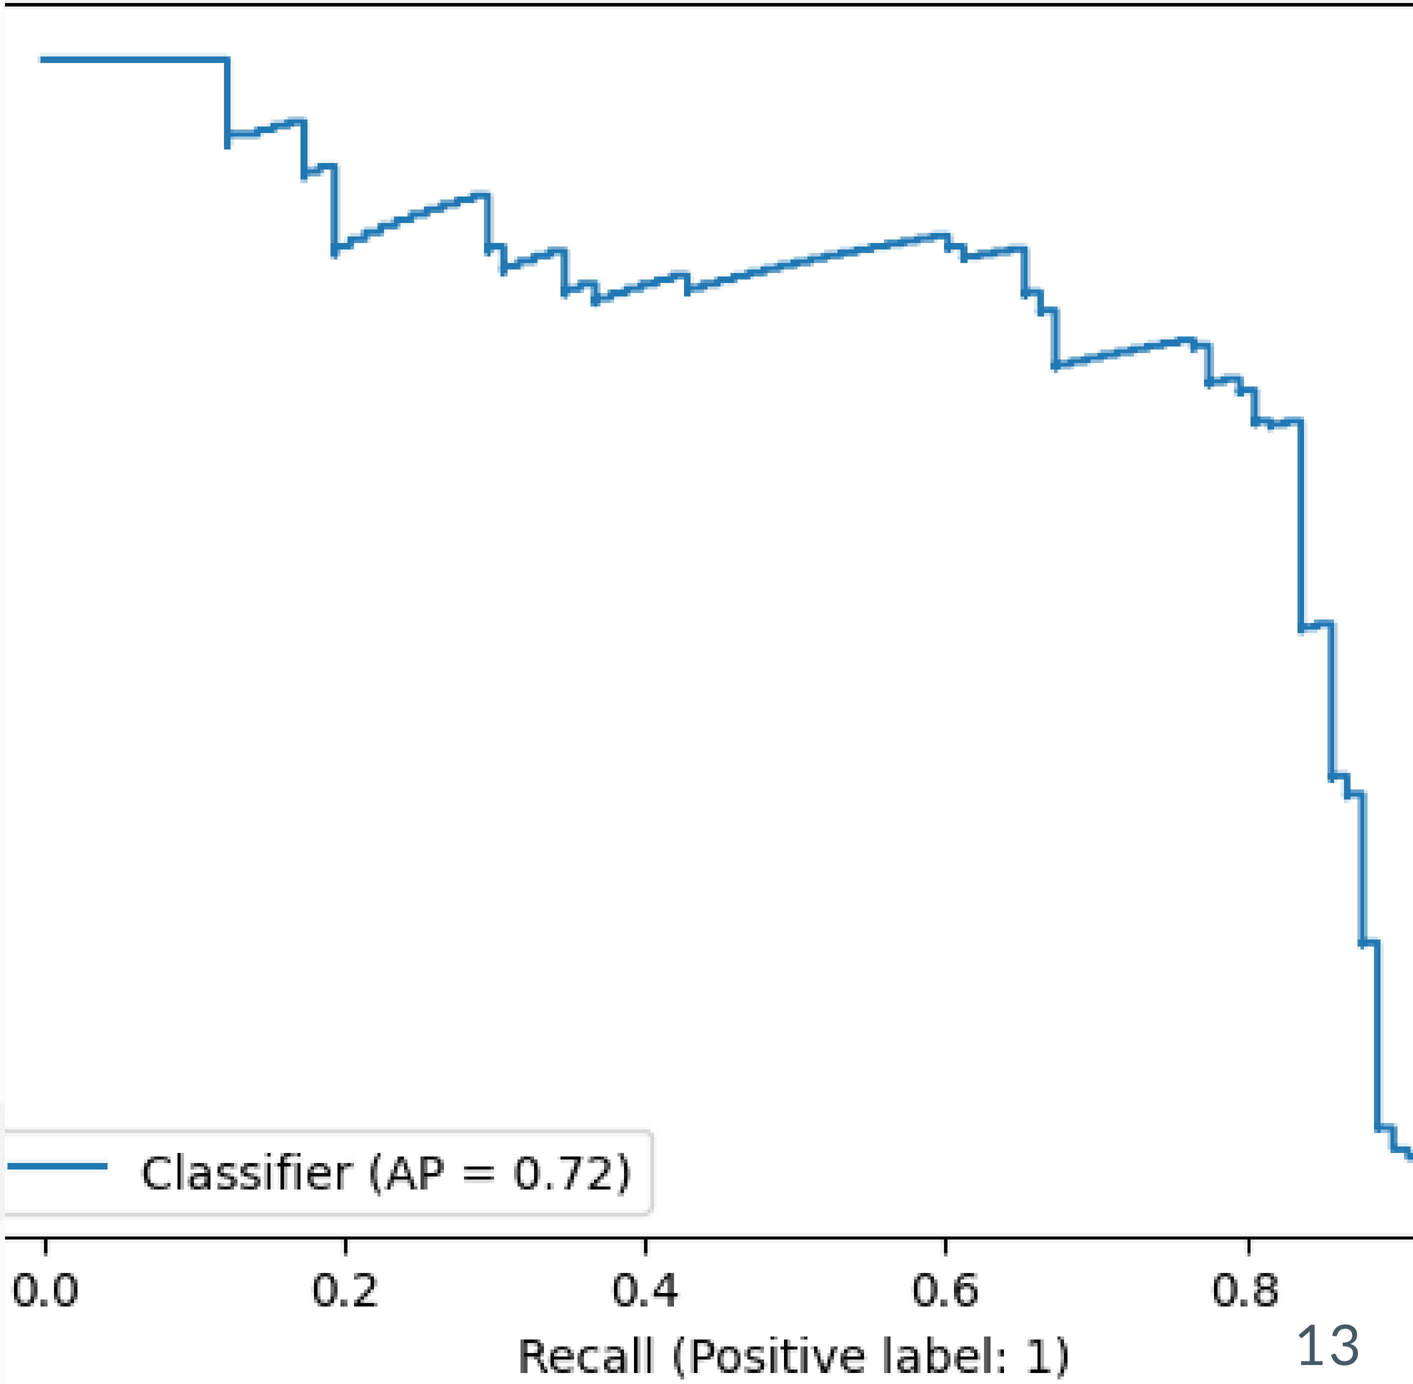

Resultados (cont.)

Matriz de confusão da regressão logística

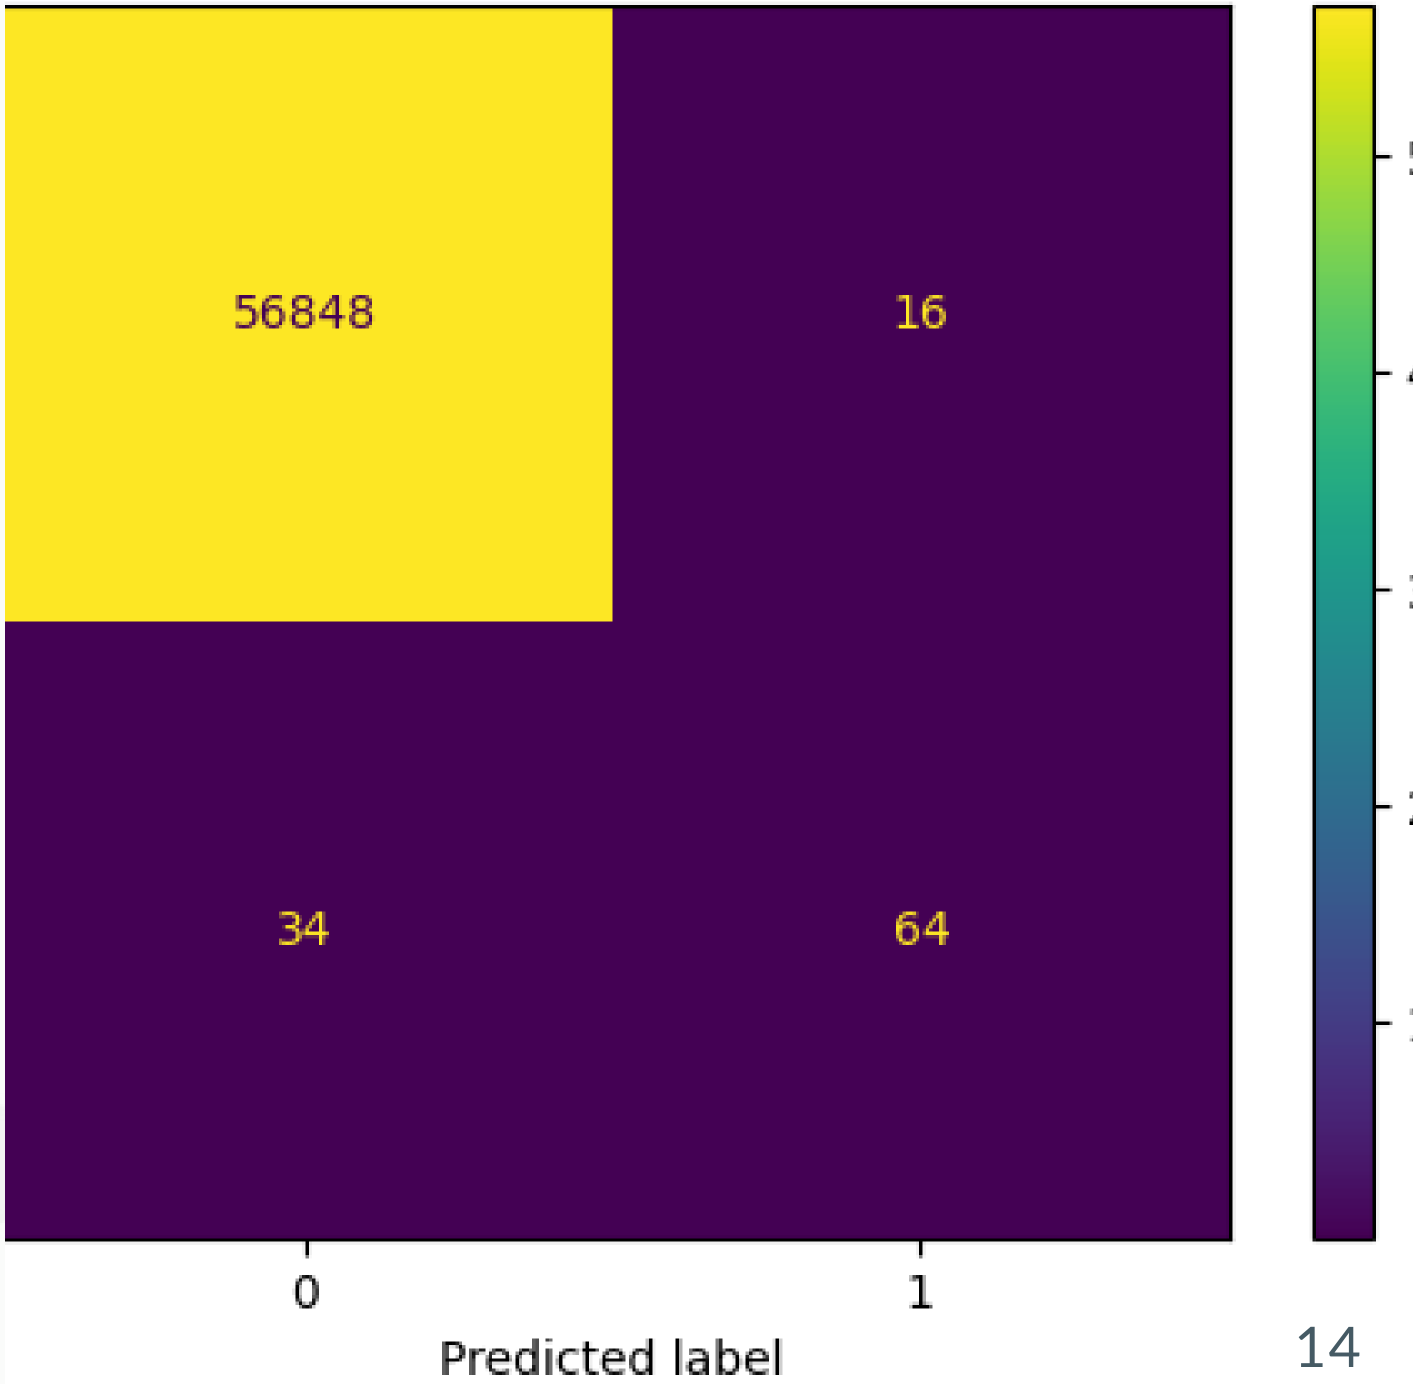

Resultados (cont.)

Relatório de classificação

```
              precision    recall  f1-score   support

           0       1.00      1.00      1.00     56864
           1       0.80      0.65      0.72        98

    accuracy                           1.00     56962
   macro avg       0.90      0.83      0.86     56962
weighted avg       1.00      1.00      1.00     5696
```

Resultados (cont.)

Importância das variáveis do *gradient boosting*

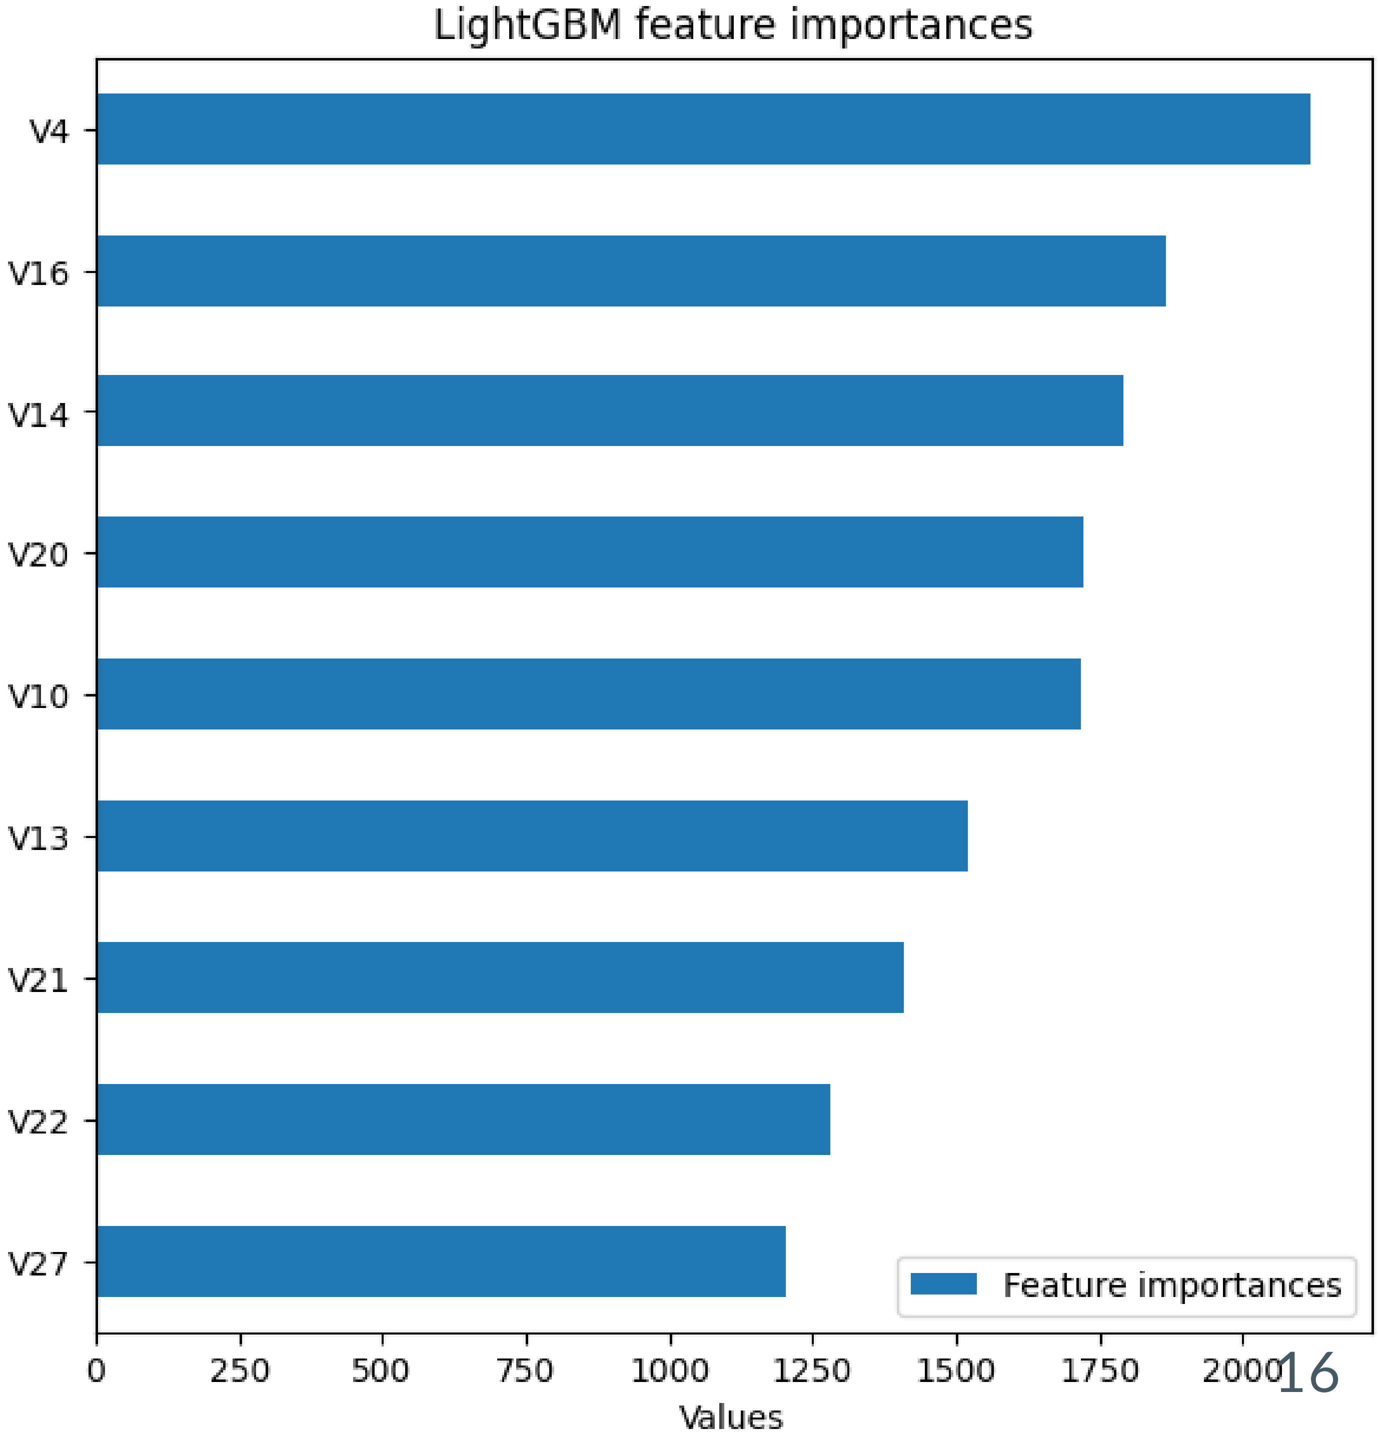

Resultados (cont.)

Curva de precisão-revocação do *gradient boosting*

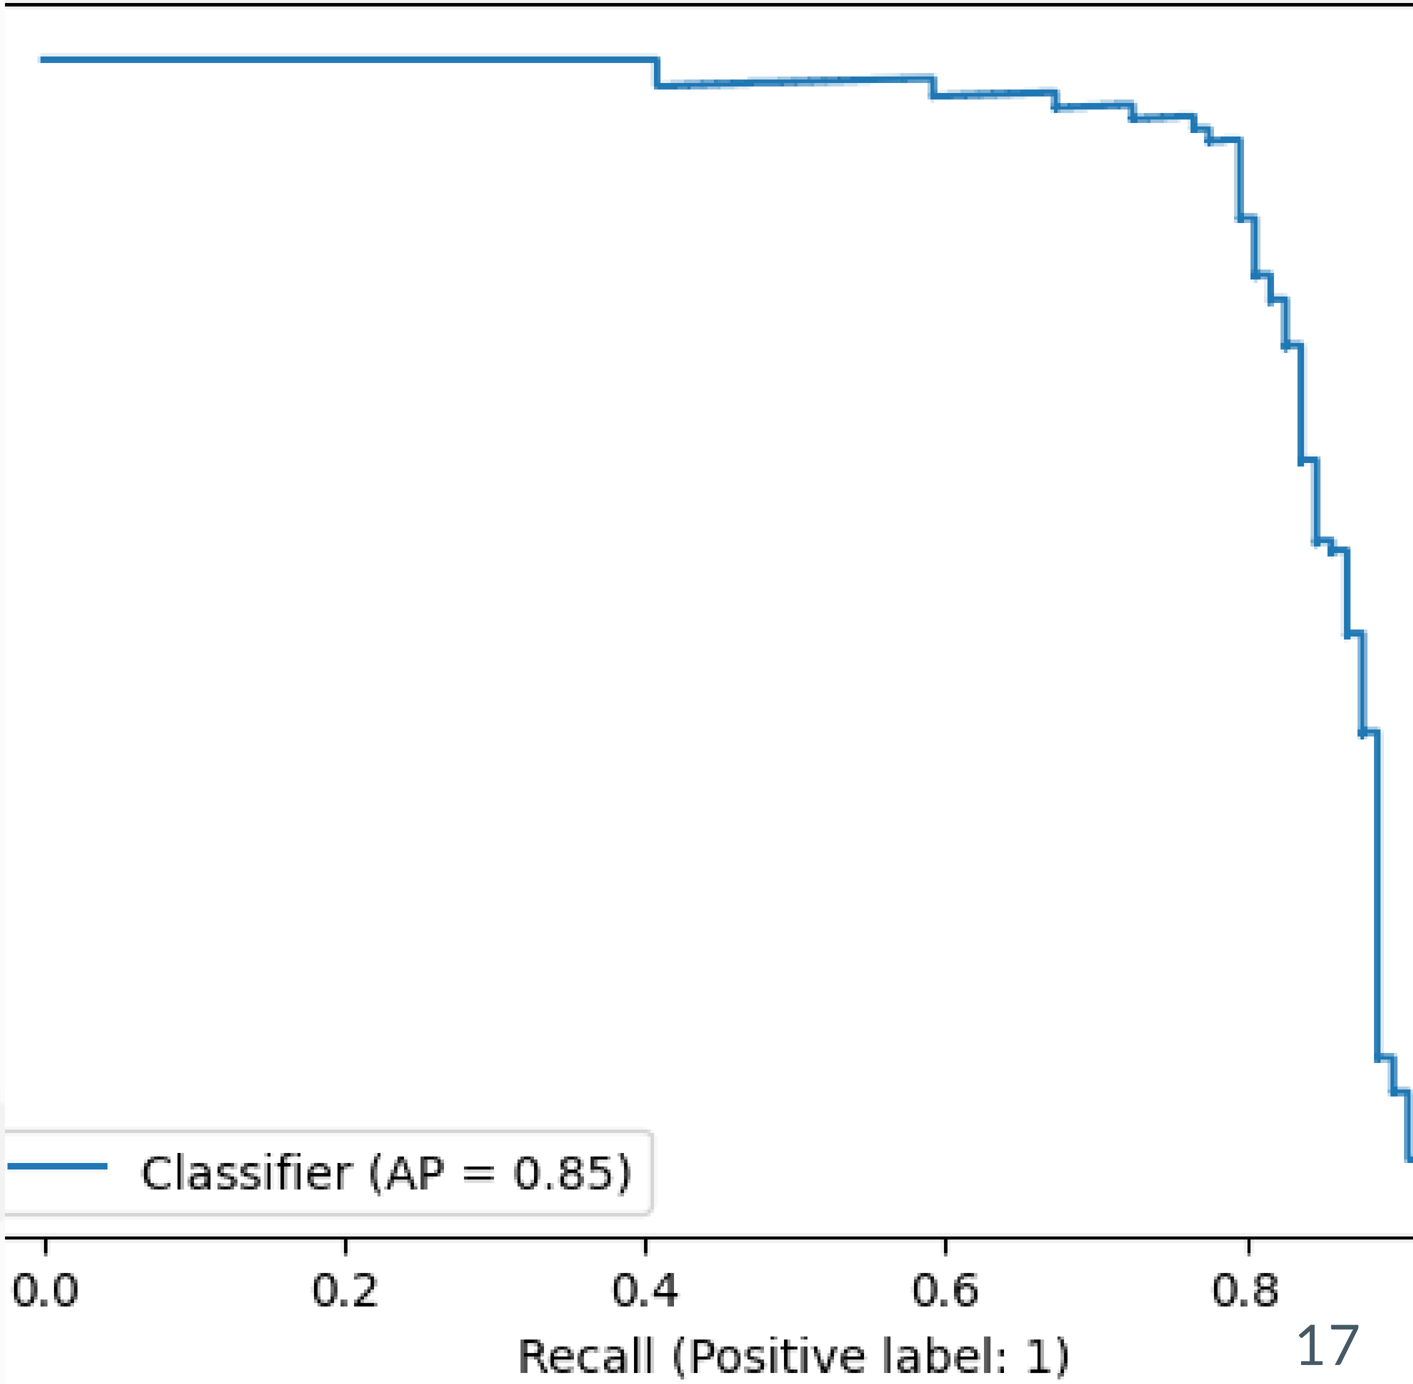

Resultados (cont.)

Matriz de confusão do *gradient boosting*

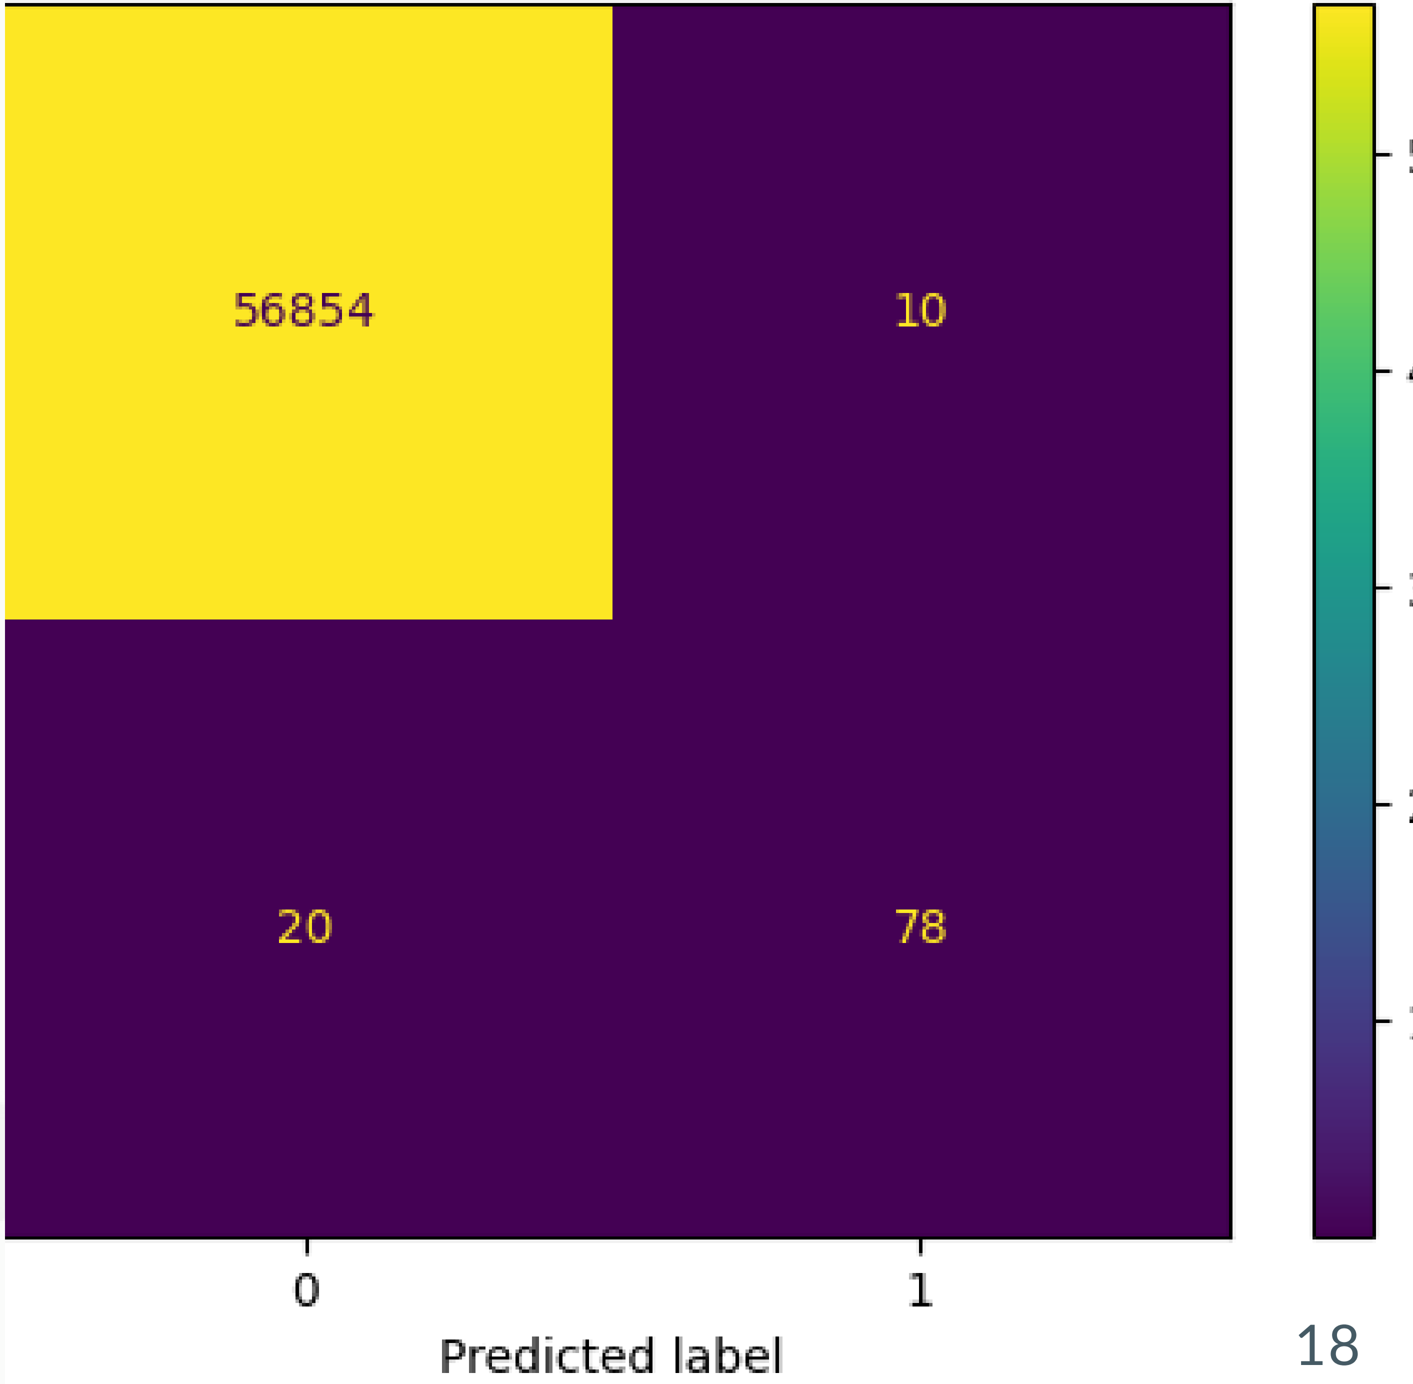

Resultados (cont.)

Relatório de classificação

```
              precision    recall  f1-score   support

           0       1.00      1.00      1.00     56864
           1       0.89      0.80      0.84        98

    accuracy                           1.00     56962
   macro avg       0.94      0.90      0.92     56962
weighted avg       1.00      1.00      1.00     56962
```

Conclusões

Dada a performance superior do *gradient boosting*, recomendamos o seu *deploy*.